

2018 FAST CAMPUS

DATA SCIENCE SCHOOL PROJECT(1)

REGRESSION ANALYSIS TEAM: FORTUNETELLER





- 01. INTRODUCTION
- 02. EDA
- 03. FEATURE SELECTION
- 04. OLS MODELING
- 05. CONCLUSION
- 06. 시계열 모형 (MOVING AVERAGE)
- 07. SUMMARY



1. INTRODUCTION

Walmart Recruiting II: Sales in Stormy Weather



Objective

• Predict how sales of weather - sensitive products are affected by snow and rain

Data Set

- Weather: 2012.01.01 2014.10.31의 각 station날씨
- Key: Store와 Weather Station간의 관계 Mapping
- Train: 2012.01.01 2014.10.31의 각 Store, Item 별 Units Data (test날짜 제외)
- Test: 2013.04.01 이후 Weather Event가 발생한 전후 3일



1. INTRODUCTION (Continued)

Walmart Recruiting II: Sales in Stormy Weather



Rules

- 외부데이터 사용 금지
- Train data set에서 2013-04-01 이전 데이터를 Training data로 정의한다
- You do not need to forecast weather in addition to sales (it's as though you have a perfect weather forecast at your disposal)

Assumptions

- Weather event는 문제에서 정의한 Preciptotal > 1 inch, Snowfall > 2inch 를 따른다
- Target value "units"는 독립변수(들)의 선형조합이다



1. INTRODUCTION (Continued)

Walmart Recruiting II: Sales in Stormy Weather

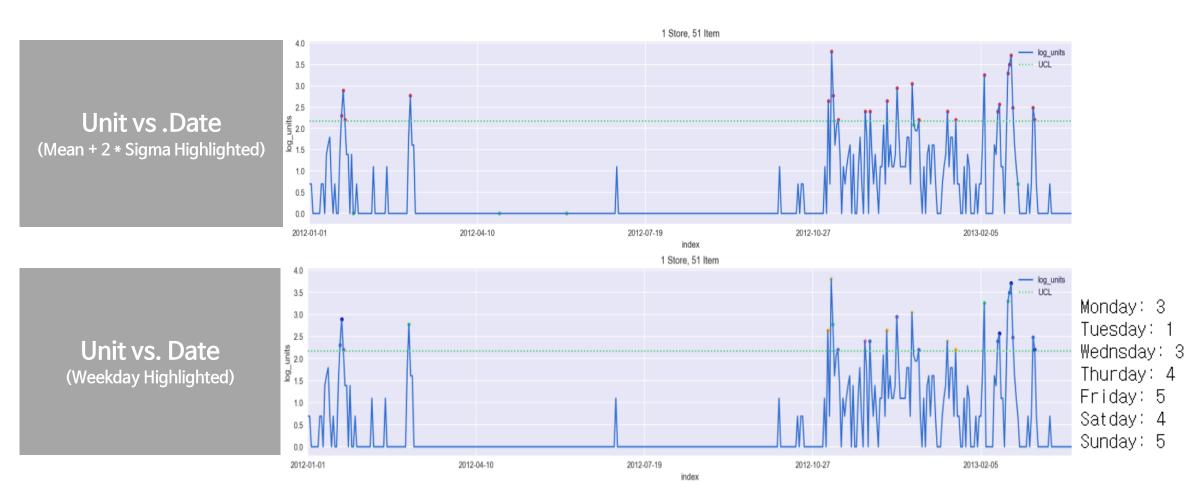


Weather Columns

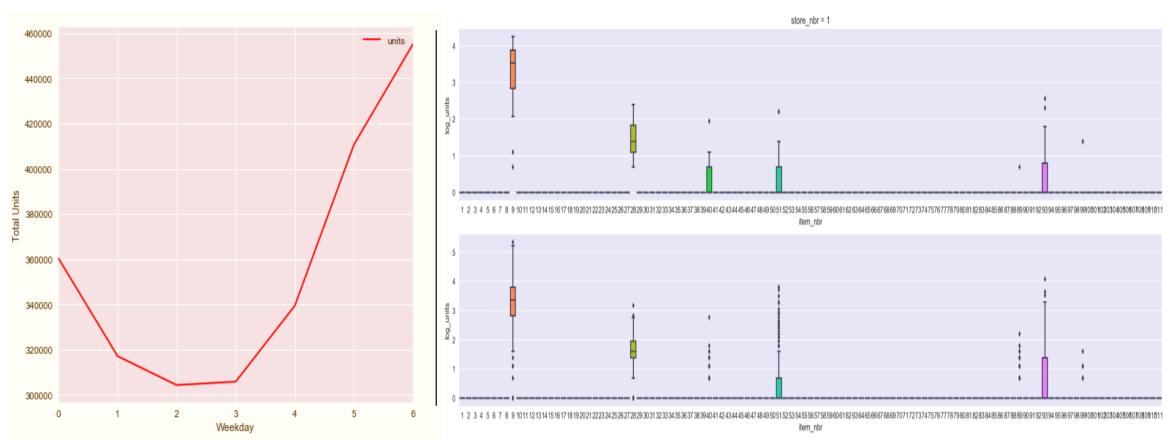
- tmax(최고 기온, °F), tmin(최저 기온, °F), tavg(평균 기온, °F), depart(30년간 평균 기온과 tavg의 차이, °F),
- dewpoint(이슬점, °F), wetbulb(습구온도, °F), heat(65°F tavg), cool(tavg 65°F)
- sunrise(일출시간), sunset(일몰시간), codesum(RA:rain, SN:snow 등 36개의 특이 날씨)
- snowfall(적설량, inches), preciptotal(강수량, inches)
- Stnpressure(평균기압, inchHg), sealevel(해수면기압, inchHg)
- Resultspeed(합성풍속, mph), resultdir(합성 풍향, 00:북, 09:동, 18:남, 27:서), avgspeed(평균 풍속, mph)



2. EDA (Exploratory data analysis)



2. EDA (Exploratory data analysis)



[1] 요일 별 유닛 총 판매량

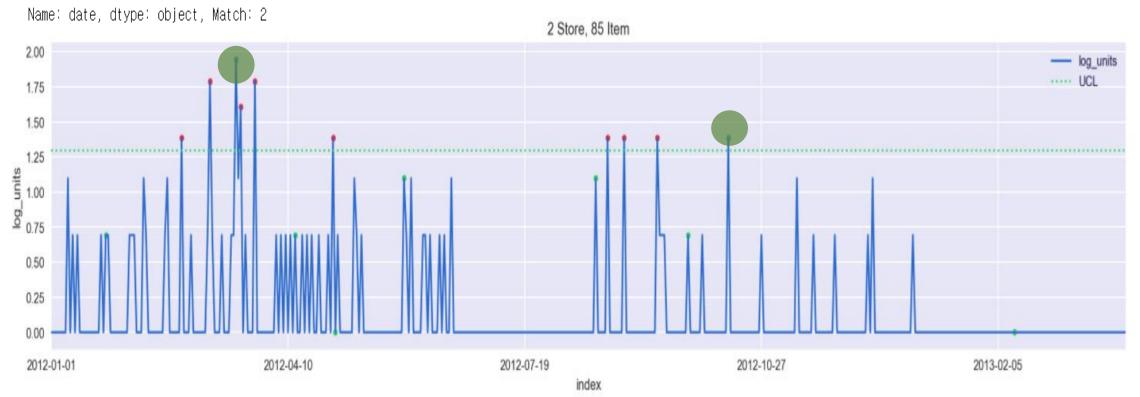
[2] Store_nbr 1의 아이템별 공휴일/비공휴일 판매량

2. EDA (Exploratory data analysis)

Unit vs Date (Weather Event Highlighted)

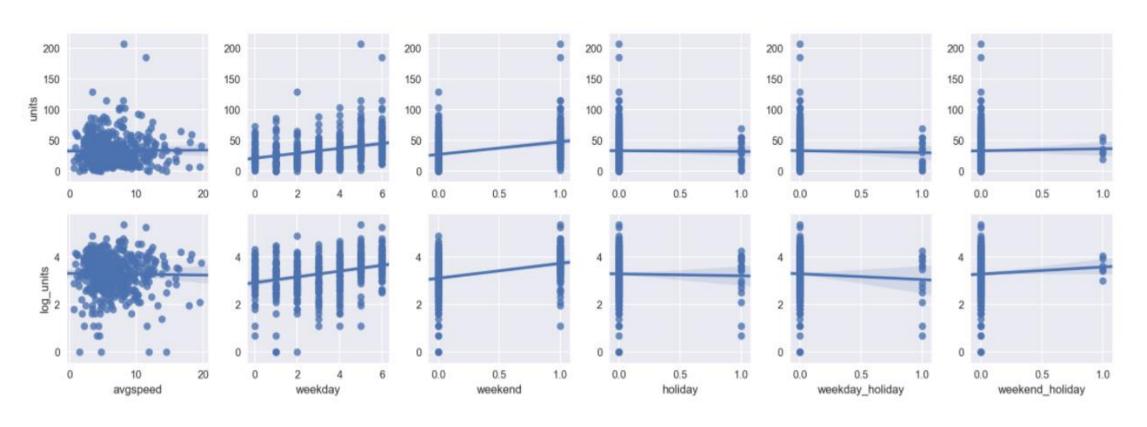
Warning!: 85221 2012-03-19

177573 2012-10-13



2. EDA (Exploratory data analysis)

1번 스토어 9번 아이템 Pair Plot



2. EDA (Exploratory data analysis)

1번 스토어 9번 아이템 Correlation Plot

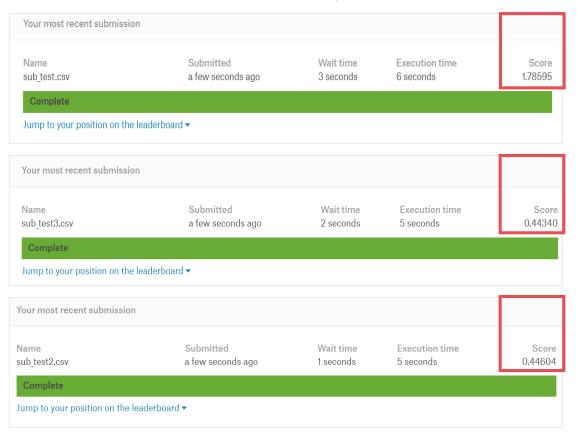
weekend_holiday	0.00	-0.00	0.00	-0.00	0.00	-0.00	-0.00	-0.00	-0.00	-0.00	0.00	-0.00	0.00	0.00	0.01		0.17	0.18	0.54	-0.02	
-																					
weekday_holiday	0.00	0.00	0.00	-0.00	-0.00 0.00	0.00	0.00	0.00	-0.00	0.00	-0.00 0.00	0.00	0.00	0.00	-0.02 0.01		-0.17 0.17	-0.11 0.18		1.00	-0.02 1.00
holiday	0.00	-0.00	0.00	-0.00	-0.00	-0.00	0.00	-0.00	-0.00	0.00	-0.00	0.00	0.00	0.00	-0.01	-0.03	-0.05	0.00	1.00	0.83	0.54
weekend	-0.00	0.00	0.00	0.00	-0.00	-0.00	0.00	-0.00	-0.00	-0.00	-0.00	-0.00	-0.00	-0.00	0.38	0.36	0.79	1.00	0.00	-0.11	0.18
weekday	0.00	-0.00	-0.00	0.00	0.00	0.00	0.00	0.00	-0.00	0.00	-0.00	-0.00	0.00	0.00	0.32	0.30	1.00	0.79	-0.05	-0.17	0.17
log_units	-0.00	-0.00	-0.00	-0.00	0.00	0.00	-0.00	-0.00	0.00	0.00	-0.00	-0.00	0.00	0.00	0.88	1.00	0.30	0.36	-0.03	-0.06	0.04
units	0.00	-0.00	-0.00	-0.00	0.00	-0.00	0.00	-0.00	-0.00	0.00	0.00	-0.00	0.00	0.00	1.00	0.88	0.32	0.38	-0.01	-0.02	0.01

- 각 Store_nbr, Item_nbr별로 나누어 Modeling해야 한다.
- Weather와 log_units(또는 units)는 큰 상관관계가 없어 보인다.
- Weekday와 Holiday가 log_units(또는 units)와 약간의 상관관계가 있어 보인다.(Item_nbr에 따라 다름)



4. OLS MODELING (Trial & Error)

Trial Test



Trial 1. 2등(뒤에서)

log_units ~ C(store_nbr) + C(item_nbr) + C(weekday) + C(holiday) + C(event) + 0

Trial 2. 485명중 350등

C(store_nbr):C(item_nbr) + C(weekday) + C(holiday) + C(event) + 0

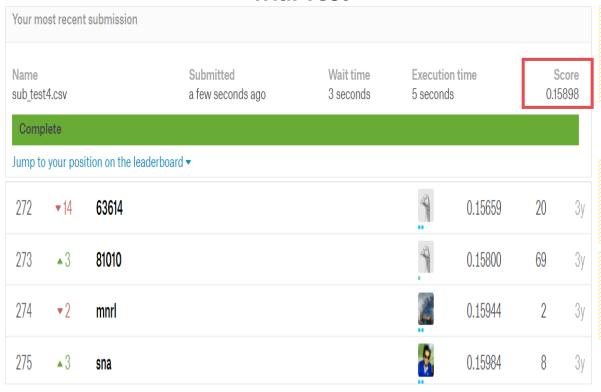
Trial 2-1

C(store_nbr):C(item_nbr) + C(weekday) + C(holiday) + snowfall + preciptotal + 0



4. OLS MODELING (Trial & Error)

Trial Test



Trial 3.

log_units ~ C(station_nbr):C(store_nbr):C(item_nbr) + C(weekday) + C(holiday) + C(event) + 0



Memory Error 발생 Station nbr별로 나눠서 OLS실행

Trial4.

 $log_units \sim C(store_nbr):C(item_nbr) + C(weekday) + C(holiday) + C(event) + 0$

Trial5.

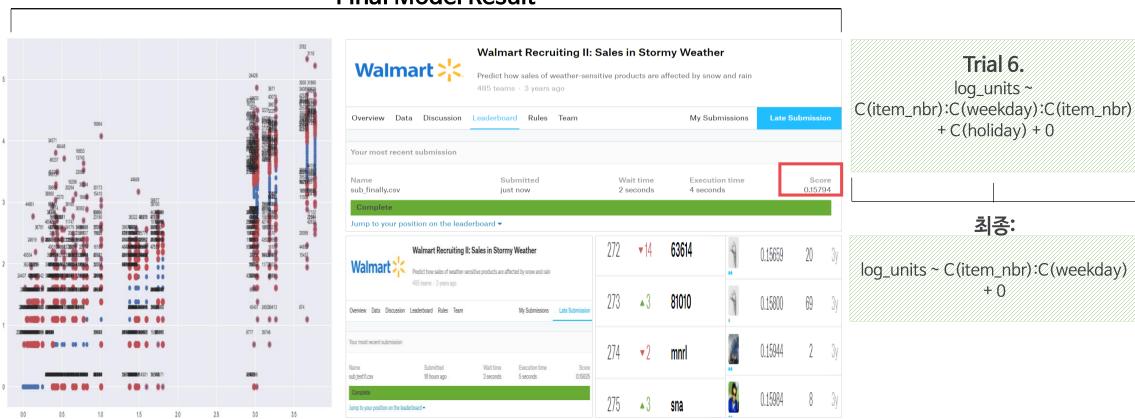
log_units ~ C(store_nbr):C(item_nbr) + C(weekday) + C(holiday) + snowfall + preciptotal + 0



Store_nbr별로 나눠서 OLS실행, Event 제외 결과 좋지 않음

4. OLS MODELING (Final)

Final Model Result





5. CONCLUSION



- 각 요일, Item_nbr별 Units의 평균치를 구하는 모델
- 잔차가 Non-normal함
 - 요인)
 - 1) Units에 영향을 주는 알 수 없는 Feature들이(Disturbance)충분히 많지 않아 정규분포로 수렴하지 못함
 - 2) 잔차끼리 독립이 아님(선형 회귀 모형이 아닌 시계열 모형을 사용해야하는 결론)

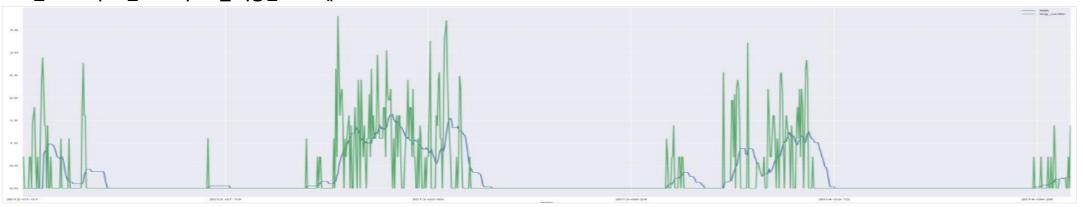


6. 시계열 모형 (MOVING AVERAGE)



			H			
96	▲ 6	35957		0.10521	26	Зу
97	▲ 13	anaef		0.10530	7	3у
98	4	Victor Mayrink	•••	0.10553	37	Зу
99	^ 1	TheAnalyticProphet	1	0.10570	23	3у
100	4 3	99247	4	0.10586	11	3у

• 1번 Store의 51번 Item의 MA을 이용한 Fit 그래프.





7. SUMMERY

- 종속변수 Units는 독립변수 Store_nbr, Item_nbr, Weekday, Holiday, Event의 선형조합으로 결정되는 기대 값과 고정된 분산을 가지는 정규분포를 따른다 라고 가정함.
- 각 스토어의 아이템별 Units vs. Date 플롯은 판매량이 Random함을 확인.
- 그 Random함이 Weekday, Holiday, Event에 영향을 받은 것인지 알아보기 위해 다수의 OLS를 시행함.
- Holiday와 Event의 영향이 없다고 판단, Item_nbr와 Weekday의 Interaction을 모수로 사용하는 OLS를 최종 모델로 채택.
- 최종 모델에서 잔차의 분포가 정규분포를 따르지 않음을 확인.
- 그 이유는 잔차 간의 독립이 성립되지 않기 때문이라고 생각.
- 잔차 간 독립이 성립하지 않음은 종속변수 간의 관계가 있음을 나타내고 따라서 시계열 모형 (이동평균선)을 이용하여 종속변수를 재추정하였고, 회귀모형보다 좋은 결과 값을 확인.

