

2018 FAST CAMPUS

DATA SCIENCE SCHOOL PROJECT(1)

REGRESSION ANALYSIS
TEAM: FORTUNETELLER

싱 가 영 조 영 민 하 조 의



목차

- 01. INTRODUCTION
- 02. EDA
- **03. FEATURE SELECTION**
- 04. OLS MODELING
- 05. CONCLUSION
- 06. 시계열 모형 (MOVING AVERAGE)
- 07. SUMMARY



1. INTRODUCTION

Walmart Recruiting II: Sales in Stormy Weather



Objective

Predict how sales of weather – sensitive products are affected by snow and rain

Data Set

• Weather : 2012.01.01 – 2014.10.31의 각 station날씨

• Key : Store와 Weather Station간의 관계 Mapping

• Train : 2012.01.01 – 2014.10.31의 각 Store, Item 별 Units Data (test날짜 제외)

• Test : 2013.04.01 이후 Weather Event가 발생한 전후 3일



1. INTRODUCTION (Continued)

Walmart Recruiting II: Sales in Stormy Weather



Weather Columns

- tmax (최고 기온, °F), tmin (최저 기온, °F), tavg (평균 기온, °F), depart (30년간 평균 기온과 tavg의 차이, °F),
- dewpoint (이슬점, °F), wetbulb (습구온도, °F), heat (65°F tavg), cool (tavg 65°F)
- sunrise (일출 시간), sunset (일몰 시간), codesum (RA:rain, SN:snow 등 36개의 특이 날씨)
- snowfall (적설량, inches), preciptotal (강수량, inches)
- stnpressure (평균 기압, inchHg), sealevel (해수면 기압, inchHg)
- resultspeed (합성풍속, mph), resultdir (합성 풍향, 00:북, 09:동, 18:남, 27:서) , avgspeed (평균 풍속, mph)



1. INTRODUCTION (Continued)

Walmart Recruiting II: Sales in Stormy Weather



Rules

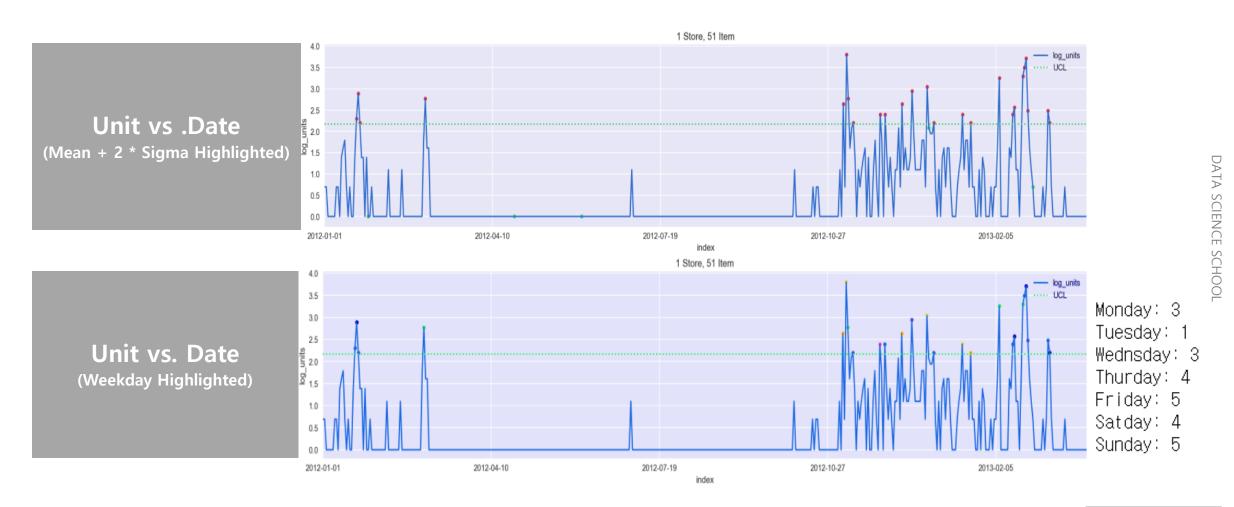
- 외부데이터 사용 금지
- Train data set에서 2013-04-01 이전 데이터를 Training data로 정의한다
- You do not need to forecast weather in addition to sales (it's as though you have a perfect weather forecast at your disposal)

Assumptions

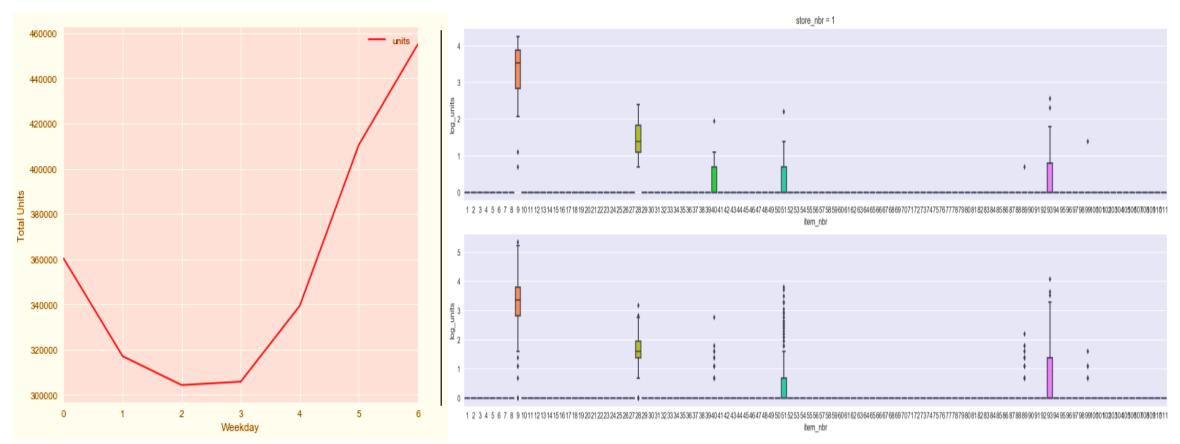
- Weather event는 문제에서 정의한 Preciptotal > 1 inch, Snowfall > 2inch 를 따른다
- Target value "units"는 독립변수(들)의 선형조합이다



2. EDA(Exploratory data analysis)



2. EDA(Exploratory data analysis)



[1] 요일 별 유닛 총 판매량

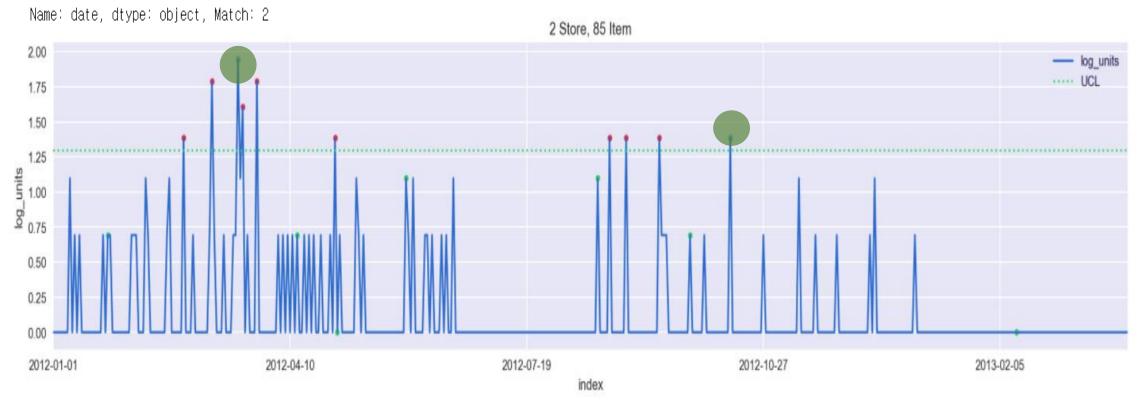
[2] Store_nbr 1의 아이템별 공휴일/비공휴일 판매량

2. EDA(Exploratory data analysis)

Unit vs Date (Weather Event Highlighted)

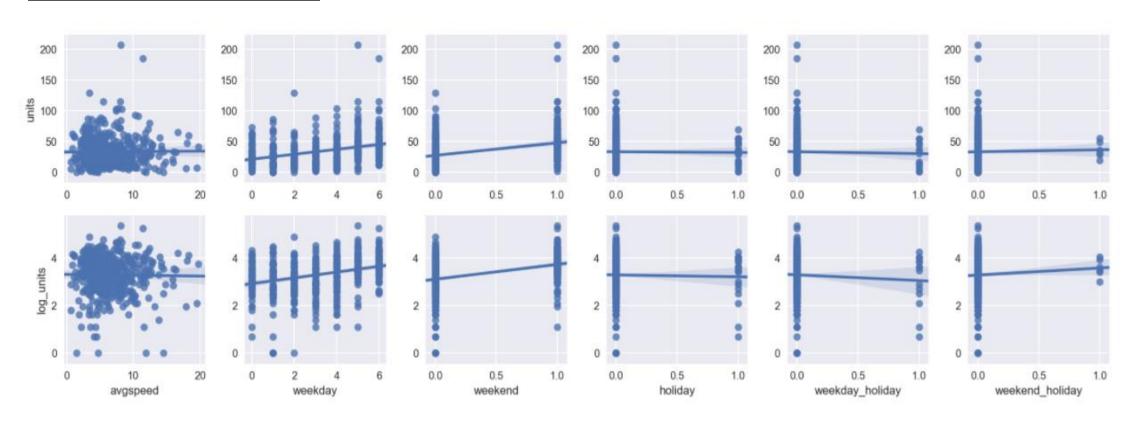
Warning!: 85221 2012-03-19

177573 2012-10-13



2. EDA(Exploratory data analysis)

1번 스토어 9번 아이템 Pair Plot



2. EDA(Exploratory data analysis)

1번 스토어 9번 아이템 Correlation Plot

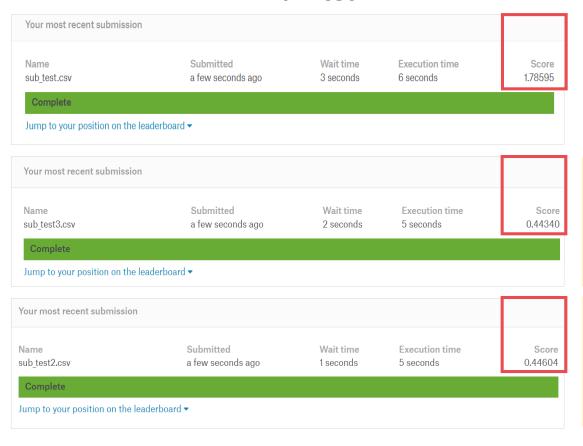
									I								l								
units	0.00	-0.00	-0.00		-0.00	0.00	-0.00	0.00		-0.00	-0.00	0.00	0.00	-0.00	0.00	0.00			1.00	0.88	0.32	0.38	-0.01	-0.02	0.01
log_units	-0.00	-0.00	-0.00		-0.00	0.00	0.00	-0.00		-0.00	0.00	0.00	-0.00	-0.00	0.00	0.00			0.88	1.00	0.30	0.36	-0.03	-0.06	0.04
weekday	0.00	-0.00	-0.00		0.00	0.00	0.00	0.00		0.00	-0.00	0.00	-0.00	-0.00	0.00	0.00			0.32	0.30	1.00	0.79	-0.05	-0.17	0.17
weekend	-0.00	0.00	0.00		0.00	-0.00	-0.00	0.00		-0.00	-0.00	-0.00	-0.00	-0.00	-0.00	-0.00			0.38	0.36	0.79	1.00	0.00	-0.11	0.18
holiday	0.00	-0.00	0.00		-0.00	-0.00	-0.00	0.00		-0.00	-0.00	0.00	-0.00	0.00	0.00	0.00			-0.01	-0.03	-0.05	0.00	1.00	0.83	0.54
weekday_holiday	0.00	0.00	0.00		-0.00	-0.00	0.00	0.00		0.00	-0.00	0.00	-0.00	0.00	0.00	0.00			-0.02	-0.06	-0.17	-0.11	0.83	1.00	-0.02
weekend_holiday	0.00	-0.00	0.00		-0.00	0.00	-0.00	-0.00		-0.00	-0.00	-0.00	0.00	-0.00	0.00	0.00			0.01	0.04	0.17	0.18	0.54	-0.02	1.00
	tmax	tmin	tavg	depart	dewpoint	wetbulb	heat	looo	snowfall	preciptotal	stnpressure	sealevel	resultspeed	resultdir	avgspeed	event	store_nbr	item_nbr	units	log_units	weekday	weekend	holiday	day_holiday	end_holiday
3. FEATU	JRE	SE	LE	СТІ	ON																			week	week

- 각 Store_nbr, Item_nbr별로 나누어 Modeling해야 한다
- Weather와 log_units(또는 units)는 큰 상관관계가 없어 보인다
- Weekday와 Holiday가 log_units (또는 units)와 약간의 상관관계가 있어 보인다 (Item_nbr에 따라 다름)



4. OLS MODELING (Trial & Error)

Trial Test



Trial 1. 2등(뒤에서)

log_units ~ C(store_nbr) + C(item_nbr) + C(weekday) + C(holiday) + C(event) + 0

Trial 2. 485명중 350등

C(store_nbr):C(item_nbr) + C(weekday) + C(holiday) + C(event) + 0

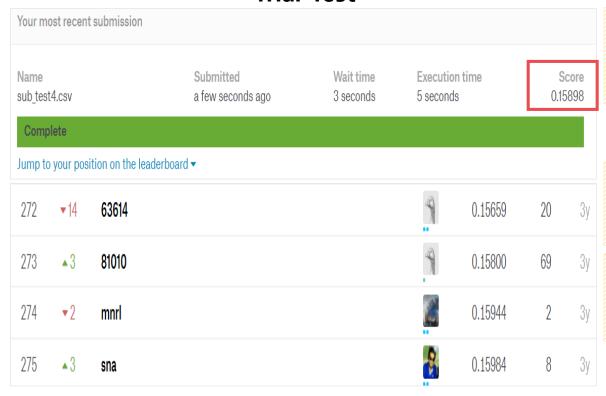
Trial 2-1

C(store_nbr):C(item_nbr) + C(weekday) + C(holiday) + snowfall + preciptotal + 0



4. OLS MODELING (Trial & Error)

Trial Test



Trial 3.

log_units ~ C(station_nbr):C(store_nbr):C(item_nbr) + C(weekday) + C(holiday) + C(event) + 0



Memory Error 발생 Station_nbr별로 나눠서 OLS실행

Trial4.

log_units ~ C(store_nbr):C(item_nbr) + C(weekday) + C(holiday) + C(event) + 0

Trial5.

log_units ~ C(store_nbr):C(item_nbr) + C(weekday) + C(holiday) + snowfall + preciptotal + 0

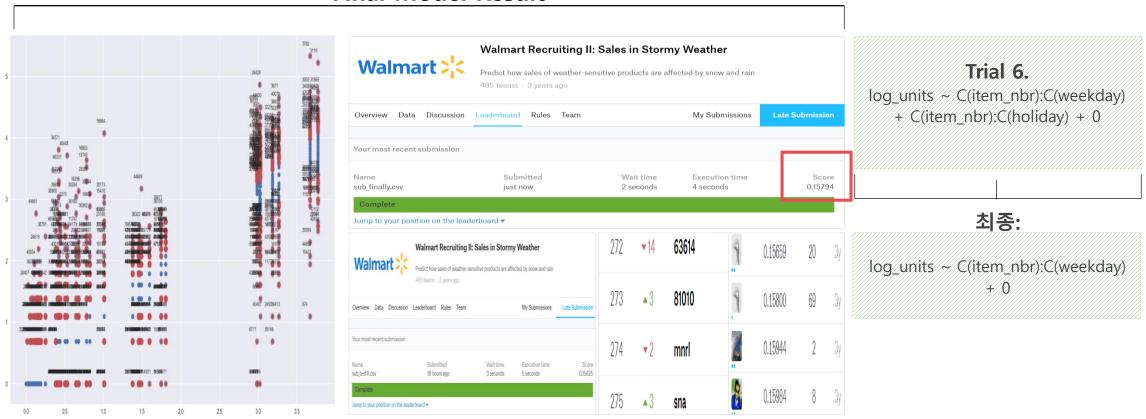


Store_nbr별로 나눠서 OLS실행, Event 제외 결과 좋지 않음



4. OLS MODELING (Final)

Final Model Result





4. OLS MODELING (Final)

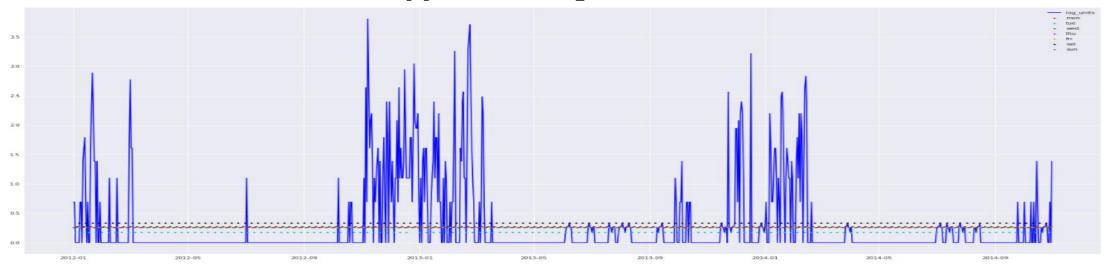
(Store_nbr 1) Final Model Result Summary

l	OLS Regression Results								OLS Regres	sion Results						·
Dep. Yariable: Model: Method: Date: Time: No. Observations: Df Residuals: Df Model: Covariance Type:	log_units R-squared: OLS Adj. R-squared: Least Squares F-statistic: Thu, 15 Mar 2018 Prob (F-statistic) 18:37:53 Log-Likelihood: 50505 AIC: 49728 BIC: 776 nonrobust):	0.842 0.839 340.5 0.00 23410. -4.527e+04 -3.840e+04						log_units	R-squared: Adj. R-squared: F-statistic: Prob (F-statistic): Log-Likelihood: AIC: BIC:		0.995 0.995 1.219e+04 0.00 1.1342e+05 -2.253e+05 -2.184e+05				
		coef	std err	t	P> t	[0.025	0.975]				coef	std err	t	P> t	[0.025	0.975]
C(item_nbr)[2]:C(week	kday, contrast_weekday)[custom0] kday, contrast_weekday)[custom0] kday, contrast_weekday)[custom0]	0 0 0	0.019 0.019 0.019	0 0 0	1.000 1.000 1.000	-0.037 -0.037 -0.037	0.037 0.037 0.037	C(item_nbr)[1]:C(weekday, C(item_nbr)[2]:C(weekday, C(item_nbr)[3]:C(weekday,	contrast_wee	kday)[custom0]	0 0 0	0.003 0.003 0.003	0 0 0	1.000 1.000 1.000	-0.006 -0.006 -0.006	0.006 0.006 0.006
C(item_nbr)[110]:C(we	eekday, contrast_weekday)[custom6] eekday, contrast_weekday)[custom6] eekday, contrast_weekday)[custom6]	0 0 0	0.019 0.019 0.019	0 0 0	1.000 1.000 1.000	-0.037 -0.037 -0.037	0.037	C(item_nbr)[109]:C(weekday C(item_nbr)[110]:C(weekday C(item_nbr)[111]:C(weekday	, contrast_w	eekday)[custom6]	0 0 0	0.003 0.003 0.003	0 0 0	1.000 1.000 1.000	-0.006 -0.006 -0.006	0.006 0.006 0.006
Omnibus: Prob(Omnibus): Skew: Kurtosis:	46753.784 Durbin-Watson: 0.000 Jarque-Bera (JB): 3.588 Prob(JB): 109.165 Cond. No.		2.000 23826967.194 0.00 1.02					Omnibus: Prob(Omnibus): Skew: Kurtosis:	33790.919 0.000 1.767 140.571	Durbin-Watson: Jarque-Bera (JB): Prob(JB): Cond. No.	3	2.000 39853352.566 0.00 1.02				



5. CONCLUSION

[3] 1번 Store Item_nbr 51



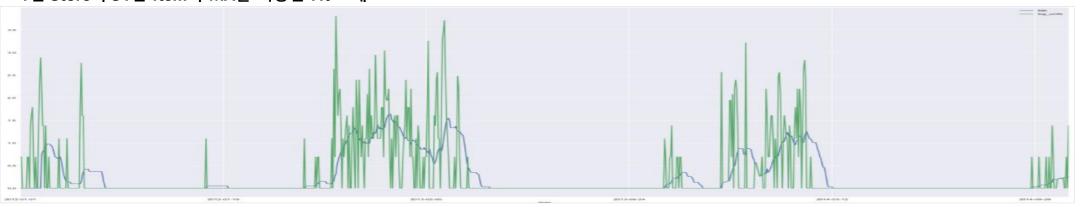
- 각 요일, Item_nbr별 Units의 평균치를 구하는 모델
- 잔차분포가 Non-normal함
 - 요인)
 - 1) Units에 영향을 주는 알 수 없는 Feature들이(Disturbance)충분히 많지 않아 정규분포로 수렴하지 못함
 - 2) 잔차끼리 독립이 아님(선형 회귀 모형이 아닌 시계열 모형을 사용하는 것이 적합해 보임)

6. 시계열 모형 (MOVING AVERAGE)



					н			
	96	6	4 6	35957	4	0.10521	26	3у
n	97	7	▲ 13	anaef		0.10530	7	3у
	98	8	4	Victor Mayrink		0.10553	37	Зу
e 3	99	9	^ 1	TheAnalyticProphet	9	0.10570	23	Зу
	100	0	4 3	99247	4	0.10586	11	Зу

• 1번 Store의 51번 Item의 MA을 이용한 Fit 그래프





7. SUMMERY

- 종속변수 Units는 독립변수 Store_nbr, Item_nbr, Weekday, Holiday, Event의 선형조합으로 결정되는 기대 값과 고정된 분산을 가지는 정규분포를 따른다 라고 가정함
- 각 스토어의 아이템별 Units vs. Date 플롯은 판매량이 Random함을 확인
- 그 Random함이 Weekday, Holiday, Event에 영향을 받은 것인지 알아보기 위해 다수의 OLS를 시행함
- Holiday와 Event의 영향이 없다고 판단, Item_nbr와 Weekday의 Interaction을 모수로 사용하는 OLS를 최종 모델로 채택
- 최종 모델에서 잔차의 분포가 정규분포를 따르지 않음을 확인
- 그 이유는 잔차 간의 독립이 성립되지 않기 때문이라고 생각
- 잔차 간 독립이 성립하지 않음은 종속변수 간의 관계가 있음을 나타내고 따라서 시계열 모형 (이동평균선)을 이용하여 종속변수를 재추정하였고, 회귀모형보다 좋은 결과 값을 확인

